

# Araba Gövde Tipi Sınıflandırma Projesi: EfficientNet-B0 Tabanlı Derin Öğrenme Yaklaşımı ve Web Arayüz Entegrasyonu

Abdullah Amin  
Bilgisayar Mühendisliği Bölümü  
Kocaeli Üniversitesi  
Kocaeli, Türkiye  
210201142@kocaeli.edu.tr

**Özet**—Otomotiv endüstrisi ve akıllı ulaşım sistemlerinde otom analizlerin hız kazanması, araçların görsel özelliklerinden otomatik olarak tanınmasını ve sınıflandırılmasını kritik bir problem haline getirmiştir. Bu çalışmada, sekiz farklı araba gövde tipinin (SUV, VAN, STATION WAGON, MICRO, F1, SEDAN, HATCHBACK ve PICK\_UP) görüntüler üzerinden yüksek doğrulukla otomatik olarak sınıflandırılması amaçlanmıştır. Proje kapsamında, farklı kaynaklardan derlenen ve sınıf dengesi gözetilerek özelleştirilen kapsamlı bir veri seti hazırlanmıştır. Görüntüler üzerinde yöneltme düzeltmesi, en-boy oranı korunarak (letterbox) yeniden boyutlandırma ve çift kopya temizliği gibi titiz ön işleme adımları uygulanmış; modelin genelleme yeteneğini artırmak amacıyla çeşitli veri artırma (data augmentation) teknikleri kullanılmıştır. Sınıflandırma görevinde, parametre verimliliği ve yüksek başarımla öne çıkan EfficientNet-B0 mimarisi tercih edilmiş ve ImageNet ağırlıkları kullanılarak transfer öğrenme (transfer learning) yöntemiyle ince ayar (fine-tuning) yapılmıştır. Eğitim süreci boyunca accuracy, precision, recall, F1-score ve balanced accuracy gibi çok yönlü performans metrikleri takip edilmiştir. Elde edilen model modern bir web arayüzüne ve ayrıca verilen tahmin scripti formatına uygun bir paketleme yapısına entegre edilmiş, kullanıcıların yüklediği araç görselleri üzerinde gerçek zamanlı ve güven skorlu tahmin yapılması sağlanmıştır. DeneySEL sonuçlar, önerilen derin öğrenme yaklaşımının sınıf içi farklılıklar ve sınıflar arası benzerlikler gibi zorlukların üstesinden gelerek yüksek başarımlı gösterdiğini ve geliştirilen kullanıcı dostu sistemin pratik uygulamalara hazır olduğunu kanıtlamaktadır.

**Anahtar Kelimeler**—Görüntü sınıflandırma, derin öğrenme, EfficientNet-B0, araba gövde tipi sınıflandırma, veri artırma, web arayüz, bilgisayarlı görü

## I. GİRİŞ

Görüntü işleme ve derin öğrenme yöntemleri, nesne tanıma ve sınıflandırma problemlerinde yaygın olarak kullanılmaktadır. Otomotiv alanında araçların gövde tipine göre sınıflandırılması; akıllı ulaşım sistemleri, otomatik etiketleme, trafik analizi ve görsel veri organizasyonu gibi birçok uygulama için önemlidir. Bu projede SUV, VAN, STATION WAGON, MICRO, F1, SEDAN, HATCHBACK ve PICK\_UP olmak üzere toplam sekiz sınıf için çok sınıflı bir görüntü sınıflandırma sistemi geliştirilmiştir.

Bu çalışmanın temel katkıları şu şekildedir:

- Özelleştirilmiş ve dengeli bir araç veri seti hazırlanmıştır.

- Veri setine uygun ön işleme ve veri artırma yöntemleri uygulanmıştır.
- EfficientNet-B0 modeli transfer öğrenme ile eğitilmiştir.
- Eğitilen model hem web arayüzüne hem de verilen test scripti formatına entegre edilmiştir.
- Sonuçlar eğitim eğrileri, normalize edilmiş karışıklık matrisi ve sınıf bazlı metriklerle görselleştirilmiştir.

## II. VERİ SETİ VE ÖN İŞLEME

Görüntü sınıflandırma problemlerinde modelin başarısını belirleyen en önemli faktörlerden biri, kullanılan veri setinin kalitesi, çeşitliliği ve uygulanacak veri ön işleme (preprocessing) stratejisidir. Bu bölümde, projenin temelini oluşturan veri setinin hazırlanma süreci, veri kalitesini artırmaya yönelik işlemler ve eğitim sırasında uygulanan veri artırma teknikleri detaylandırılmıştır.

### A. Veri Toplama ve Sınıflandırma

Bu projede kullanılan veri seti, Kaggle üzerindeki açık kaynaklı araç veri setleri referans alınarak ve ek kaynaklardan yapılan derlemelerle özelleştirilerek (custom dataset) oluşturulmuştur. Nihai olarak kullanılan veri seti Kaggle üzerinde paylaşılmıştır ve [7] numaralı kaynaktan erişilebilmektedir. Sınıflandırma problemi kapsamında araçlar sekiz ana gövde tipine ayrılmıştır: *SUV*, *VAN*, *STATION WAGON*, *MICRO*, *F1* (Açık Tekerlekli), *SEDAN*, *HATCHBACK* ve *PICK\_UP*. Veri toplama aşamasında, modelin bir sınıfa doğru aşırı öğrenmesini (overfitting) ve yanlılık (bias) göstermesini engellemek amacıyla sınıflar arası veri dengesinin sağlanmasına büyük önem verilmiştir. Özellikle Sedan, Hatchback ve Station Wagon gibi görsel olarak birbirine benzeyen (yüksek inter-class similarity) araç tiplerini modelin ayırt edebilmesi için, veri setine farklı açılardan, farklı ışık koşullarında ve çeşitli arka planlarda çekilmiş yüksek kaliteli görüntüler dahil edilmiştir.

Toplanan ham veriler; eğitim (training), doğrulama (validation) ve test olmak üzere bağımsız kümelerle ayrılmıştır. Bu raporda verilen 6961 görüntülük test kümesi, tarafımızca ayrılan held-out test split'idir; modelin eğitim sürecinde kullanılmamış ve sadece nihai değerlendirme için kullanılmıştır. Su-

num sırasında verilecek tamamen yeni görüntüler ise bu küme dışında olup modelin gerçek genelleme yeteneğini ölçecektir.

### B. Görüntü Ön İşleme Adımları

Modelin eğitim sürecini daha stabil hale getirmek ve öğrenme verimliliğini maksimize etmek amacıyla, ham görüntüler modele beslenmeden önce bir dizi deterministik ön işleme adımından geçirilmiştir:

- **Yön ve Format Düzeltmesi:** Görsellerdeki EXIF bozuk yön verileri düzeltilmiş ve saydam arka plana sahip görüntüler (RGBA), özellik kaybını ve kanal uyumsuzluğunu önlemek için RGB renk uzayına dönüştürülmüştür.
- **Letterbox ve Yeniden Boyutlandırma:** Görüntülerin farklı en-boy oranlarına sahip olması, doğrudan yeniden boyutlandırma yapıldığında araçların şeklinin bozulmasına yol açmaktadır. Bu durumu önlemek için en-boy oranı korunmuş ve eksik kısımlar beyaz piksellerle (padding) doldurularak (letterbox yöntemi) tüm görseller  $320 \times 320$  piksel boyutuna getirilmiştir. Bu boyut, EfficientNet mimarisinin özellik çıkarma kapasitesi ile donanım kısıtlamaları (VRAM) arasında optimum bir denge sağlamaktadır.
- **Veri Sızıntısının Önlenmesi:** Veri setindeki potansiyel mükerrer görseller, eğitim ve test setleri arasında veri sızıntısına (data leakage) neden olabileceğinden, SHA-256 kriptografik özetleme fonksiyonu kullanılarak tespit edilmiş ve eğitim öncesinde ayıklanmıştır.
- **Normalizasyon:** Derin öğrenme modellerinin daha hızlı yakınsaması (convergence) için görüntüler, ImageNet veri setinin ortalama (mean) ve standart sapma (std) değerleri kullanılarak normalize edilmiş, böylece modelin optimize edilmesi kolaylaştırılmıştır.

### C. Veri Artırma (Data Augmentation) Teknikleri

Derin öğrenme modellerinde veri setinin sınırlı olduğu durumlarda, modelin eğitim verisini ezberlemesini önlemek ve genelleme yeteneğini artırmak kritik bir öneme sahiptir. Bu projede, eğitim aşamasında PyTorch torchvision modülü tabanlı dinamik veri artırma teknikleri uygulanarak modelin her epoch'ta farklı görüntü varyasyonları görmesi sağlanmıştır. Kullanılan EfficientNet-B0 koşusunda moderate artırma profili tercih edilmiştir. Uygulanan başlıca dönüşümler şunlardır:

- **Random Resized Crop:** Araçların görüntü içindeki boyut ve konum farklılıklarına karşı modeli ölçekten bağımsız (scale-invariant) hale getirmek için kullanılmıştır.
- **Yatay Çevirme (Horizontal Flip):** Araçların yön bağımsızlığını (sağ/sol ayrımı) öğretmek amacıyla %50 olasılıkla uygulanmıştır.
- **Renk Titreşimi (Color Jitter):** Gerçek dünyadaki farklı hava durumu ve aydınlatma koşullarını simüle etmek üzere parlaklık, kontrast ve doygunluk değerleri rastgele oranlarda değiştirilmiştir.
- **Döndürme ve Affine Dönüşümler:** Kameranin çekim açılarındaki ufak sapmaları tolere edebilmek için mak-

simum 8 derecelik rastgele döndürme ve hafif kaydırma/ölçekleme işlemleri uygulanmıştır.

- **Random Erasing:** Görüntünün rastgele küçük bir bölgesinin pikselleri maskelenerek sıfırlanmış; böylece modelin aracın tek bir spesifik özelliğine odaklanması engellenmiş, bütünü görmeye teşvik edilmiştir.

## III. MODEL MIMARISI VE EĞİTİM SÜRECİ

Proje kapsamında araba gövde tiplerinin sınıflandırılması için kullanılacak temel yapay sinir ağı mimarisinin seçimi, optimizasyon algoritmaları ve eğitim stratejisi modelin hem doğruluğunu hem de çıkarım (inference) hızını doğrudan etkilemektedir. Bu bölümde tercih edilen mimarinin teorik altyapısı ve uygulanan eğitim adımları açıklanmıştır.

### A. EfficientNet-B0 Mimarisi ve Teorik Altyapısı

Görüntü sınıflandırma görevinde temel ağ (backbone) olarak **EfficientNet-B0** modeli tercih edilmiştir. EfficientNet mimarisi, ağın derinliğini, genişliğini ve çözünürlüğünü birlikte ve dengeli biçimde büyüten *Bileşik Ölçeklendirme (Compound Scaling)* metodunu kullanmaktadır.

EfficientNet-B0, yaklaşık 5.3 milyon öğrenilebilir parametreye sahip görece hafif bir model olmasına rağmen, ImageNet veri setinde kendinden çok daha büyük modellere yakın veya üstün başarımlar sergileyebilmektedir. Modelin temel yapı taşları şunlardır:

- **MBConv (Mobile Inverted Bottleneck Convolution):** Parametre sayısını düşürürken özellik çıkarma kapasitesini koruyan depthwise separable convolution bloklarıdır.
- **Squeeze-and-Excitation (SE) Mekanizması:** Ağı her bir kanalının önem derecesini dinamik olarak öğrenmesini sağlayan bir dikkat benzeri yapıdır.
- **Swish/SiLU Aktivasyon Fonksiyonu:** Pürüzsüz gradyan akışıyla daha stabil optimizasyona yardımcı olur.
- **Sınıflandırıcı Katman (Classifier Head):** Son aşamada %30 dropout ve 8 sınıflı tam bağlı çıktı katmanı kullanılmıştır.

### B. Transfer Öğrenme ve Aşamalı İnce Ayar

Modelin sıfırdan eğitilmesi hem devasa miktarda veri hem de uzun donanım süreleri gerektirdiğinden, bu projede **Transfer Öğrenme (Transfer Learning)** yaklaşımı benimsenmiştir. Model, ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır.

Eğitim iki aşamalı bir ince ayar (fine-tuning) stratejisiyle gerçekleştirilmiştir:

- 1) **Dondurma (Freezing) Aşaması:** İlk 2 epoch boyunca modelin omurga (backbone) ağırlıkları dondurulmuş ve sadece son sınıflandırıcı katman eğitilmiştir.
- 2) **Çözme (Unfreezing) Aşaması:** Son katman belirli bir dengeye ulaştıktan sonra tüm ağ çözülerek baştan sona eğitime tabi tutulmuştur.

### C. Hiperparametreler ve Diferansiyel Öğrenme Oranları

Çalışmada ağır aşırı öğrenmesini engellemek ve optimum noktaya yakınsamasını sağlamak için özenle seçilmiş hiperparametreler kullanılmıştır:

- **Girdi Boyutu:**  $320 \times 320 \times 3$  (RGB)
- **Maksimum Epoch Sayısı:** 25
- **Freeze Epoch Sayısı:** 2
- **Batch Size:** 16 (Bellek optimizasyonu göz önünde bulundurularak seçilmiştir.)
- **Sınıflandırıcı Öğrenme Oranı (LR):**  $3 \times 10^{-4}$
- **Omurga Öğrenme Oranı (Backbone LR):**  $3 \times 10^{-5}$  (Omurgadaki ön eğitilmiş ağırlıkların çok sert değişmesini engellemek için sınıflandırıcıya göre 10 kat daha düşük seçilmiştir.)
- **Dropout Oranı:** %30
- **Weight Decay:**  $1 \times 10^{-4}$
- **Erken Durdurma (Early Stopping) Sabrı:** 8 epoch

### D. Kayıp Fonksiyonu ve Optimizasyon Stratejisi

Çok sınıflı sınıflandırma problemi için ana kayıp fonksiyonu olarak **Çapraz Entropi Kaybı (Cross-Entropy Loss)** kullanılmıştır. Eğitim setinde kalan olası sınıf dengesizliklerinin gradyan güncellemelerini domine etmesini engellemek için iki tamamlayıcı yöntem kullanılmıştır:

- 1) *Sınıf Ağırlıklı Kayıp (Class-Weighted Loss)*
- 2) *Weighted Random Sampler*

Optimizasyon algoritması olarak **AdamW** kullanılmış, öğrenme oranı planlayıcısı olarak ise **Cosine Annealing** tercih edilmiştir. Ayrıca **label smoothing** ve **gradient clipping** gibi yardımcı düzenleme teknikleri kullanılmıştır. En iyi model, doğrulama kaybı ile değil, **doğrulama balanced accuracy** metriğine göre seçilmiş ve 8 epoch boyunca iyileşme görülmediğinde erken durdurma uygulanmıştır.


### IV. ARAYÜZ ENTEGRASYONU VE SİSTEM TASARIMI

Geliştirilen derin öğrenme modelinin sadece akademik metriklerle sınırlı kalmaması ve gerçek dünya koşullarında son kullanıcılar tarafından interaktif olarak test edilebilmesi amacıyla, uçtan uca (end-to-end) bir web uygulaması tasarlanmıştır. Sistem mimarisi; kullanıcı etkileşimini sağlayan istemci (frontend) ve model çıkarımını gerçekleştiren sunucu (backend) olmak üzere iki ana bileşenden oluşmaktadır. Sistemin genel çalışma akışı Şekil 1'da gösterilmektedir.

#### A. Backend Çıkarım (Inference) Servisi

Backend servisi, eğitilmiş PyTorch modelinin ağırlıklarını belleğe yükleyen ve REST API üzerinden gelen istekleri dinleyen bir Python uygulaması olarak geliştirilmiştir. Mevcut uygulamada tahmin isteği tekli dosya yükleme (*multipart/form-data*) şeklinde alınmaktadır. Bu servisin temel görev döngüsü şu şekildedir:

- 1) **Görüntü Karşılama:** Arayüzden gönderilen araç görseli alınır.
- 2) **Çıkarım Ön İşlemesi:** Görsel, modelin eğitim aşamasında beklediği formata (RGB dönüşümü, letterbox ile



Şekil 1. Sistemin genel mimari şeması ve çalışma akışı

$320 \times 320$  boyutlandırma, ImageNet normalizasyonu ve tensor formatına dönüştürme) sokulur.

- 3) **Tahmin (Forward Pass):** Hazırlanan tensör, gradyan hesaplamaları kapatılarak (`torch.no_grad()`) modelden geçirilir.
- 4) **Softmax İşlemi:** Modelin ürettiği ham logit değerleri, sınıf olasılıklarına dönüştürülür.
- 5) **Yanıt Oluşturma:** En yüksek olasılığa sahip gövde tipi ve diğer tüm sınıfların olasılık değerleri JSON formatında frontend'e geri döndürülür.

#### B. Kullanıcı Arayüzü (Frontend) Tasarımı


Kullanıcı deneyimi (UX) ön planda tutularak geliştirilen arayüz, test verilerinin sisteme kolayca yüklenmesine olanak sağlamaktadır. Arayüzün tasarımı Şekil 2'de görülmektedir.

Sisteme görüntü yüklendiğinde, istek işlenirken kullanıcıya yükleme durumu bildirilmektedir. Yanıt alındığında arayüz iki temel bileşeni gösterir:

- **Kategorik Sonuç:** Modelin en emin olduğu araba gövde tipi.
- **Olasılık Dağılım Grafiği:** Tüm sınıflar için hesaplanan olasılıklar çubuk grafik olarak sunulur.

#### C. Test Scripti ile Entegrasyon

Proje dokümanında belirtilen ek gereksinimlerden biri, verilecek test scripti ile uyumlu bir tahmin paketi hazırlanmasıdır. Bu nedenle web arayüzünden bağımsız olarak `Predict(file_path)` fonksiyonunu içeren ayrı bir tahmin scripti de hazırlanmıştır. Bu script, verilen klasör altındaki görüntüleri okuyup modelden geçirmekte ve sonuç olarak her satırı `dosya_adi | Pred: etiket` formatında olan `Preds.txt / preds.txt` dosyasını üretmektedir. Böylece



Şekil 2. Kullanıcıların tahmin işlemi gerçekleştirdiği web arayüzü tasarımı

hem canlı arayüz kullanımı hem de otomatik değerlendirme scripti ile uyumluluk sağlanmıştır.

## V. DENEYSEL SONUÇLAR VE DEĞERLENDİRME


Model performansı; sınıflandırma doğruluğu (accuracy), kesinlik (precision), duyarlılık (recall), F1-skoru (F1-score) ve dengeli doğruluk (balanced accuracy) metrikleri kullanılarak kapsamlı bir şekilde değerlendirilmiştir. Eğitim süreci boyunca aşırı öğrenmeyi (overfitting) tespit edebilmek amacıyla eğitim ve doğrulama (validation) setleri üzerindeki kayıp (loss) ve doğruluk eğrileri eşzamanlı olarak izlenmiştir. Tüm değerlendirmeler, modelin eğitim sürecinde hiçbir şekilde görmediği bağımsız held-out test veri seti (toplam 6961 görüntü) üzerinde gerçekleştirilmiştir.

### A. Eğitim Eğrileri ve Kararlılık (Stability)


Eğitim sürecinde elde edilen training ve validation eğrileri Şekil 3’de verilmiştir. Grafikler incelendiğinde, eğitim doğruluk eğrisinin istikrarlı bir şekilde yükseldiği ve doğrulama eğrisinin de bunu küçük bir farkla takip ettiği görülmektedir. En iyi kayıtlı noktada train loss ile validation loss arasındaki fark yaklaşık 0.053, train accuracy ile validation accuracy arasındaki fark ise yaklaşık 2.03 puandır. Bu durum modelde hafif bir overfitting bulunsu da genelleme davranışının sağlıklı olduğunu göstermektedir.

### B. Sınıf Bazlı Performans ve Karışıklık Matrisi (Confusion Matrix)

Modelin hangi sınıfları daha iyi öğrendiğini ve hangi sınıfları birbiriyle karıştırdığını detaylı analiz etmek amacıyla normalize edilmiş karışıklık matrisi Şekil 4’te oluşturulmuştur. Bu matris 0.00–1.00 aralığında normalize edilmiş hücre değerleri ve ısı haritası (heatmap) yapısıyla raporlanmıştır.



Şekil 3. Training ve validation loss/accuracy eğrileri



Şekil 4. Normalize edilmiş test karışıklık matrisi

Sınıflandırıcı, özellikle belirgin geometrik hatlara sahip araçlarda yüksek başarı göstermiştir. Örneğin, **F1** sınıfında %99.50, **MICRO** sınıfında %98.72 ve **PICK\_UP** sınıfında %98.22 F1-skorları elde edilmiştir. Diğer yandan en düşük performans gösteren sınıflar **HATCHBACK** (%92.86) ve **STATION WAGON** (%94.70) olmuştur. Karışıklık matrisi incelendiğinde, bu düşüşün temel nedeninin HATCHBACK, SEDAN ve STATION WAGON sınıflarının görsel benzerlikleri olduğu görülmüştür.

### C. Nicel Sonuçlar ve Başarım Oranları

Test veri kümesi üzerinde yapılan nihai ölçümlerde, EfficientNet-B0 modelinin yüksek başarıyı sergilediği görülmüştür. Genel metrikler Tablo I’te, sınıf bazlı metrikler ise Tablo II’te verilmektedir.

Modelin genelleme yeteneğinin yüksek olması; veri artırma, dropout, label smoothing, class-weighted loss, weighted sampler ve cosine annealing gibi tekniklerin birlikte etkili şekilde kullanıldığını göstermektedir. Bununla birlikte bu sonuçların, proje için ayrılan held-out test split üzerindeki performansı gösterdiği; sunum sırasında verilecek tamamen yeni görüntülerde performansın veri dağılımına bağlı olarak değişebileceği not edilmelidir.

Tablo I  
GENEL PERFORMANS METRIKLERİ

| Metrik             | Değer  |
|--------------------|--------|
| Accuracy           | %96.47 |
| Balanced Accuracy  | %96.50 |
| Macro Precision    | %96.48 |
| Macro Recall       | %96.50 |
| Macro F1-score     | %96.48 |
| Weighted Precision | %96.48 |
| Weighted Recall    | %96.47 |
| Weighted F1-score  | %96.46 |
| Test Loss          | 0.380  |

Tablo II  
SINIF BAZLI TEST PERFORMANSI

| Sınıf         | Precision | Recall | F1    |
|---------------|-----------|--------|-------|
| F1            | 99.55     | 99.44  | 99.50 |
| HATCHBACK     | 95.42     | 90.43  | 92.86 |
| MICRO         | 98.83     | 98.60  | 98.72 |
| PICK_UP       | 98.69     | 97.75  | 98.22 |
| SEDAN         | 94.10     | 96.62  | 95.35 |
| STATION WAGON | 94.65     | 94.75  | 94.70 |
| SUV           | 94.38     | 95.96  | 95.16 |
| VAN           | 96.26     | 98.44  | 97.34 |

#### D. Model Boyutu ve Çıkarım Hızı

Proje dokümanında model boyutu ve tahmin süresi de değerlendirme kriterleri arasında yer aldığından, modelin pratik kullanım açısından temel özellikleri de ölçülmüştür. EfficientNet-B0 kontrol noktası boyutu yaklaşık **46.45 MB** olup 95 MB sınırının altındadır. Tek görüntü için ölçülen ortalama çıkarım süresi bu çalışma ortamında CPU üzerinde yaklaşık **22.34 ms/görüntü**, CUDA üzerinde ise yaklaşık **7.52 ms/görüntü** olarak gözlenmiştir. Bu değerler kullanılan donanıma göre değişebilmekle birlikte, seçilen modelin hız ve boyut açısından proje gereksinimlerini karşıladığını göstermektedir.

#### VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, otomotiv sektöründe sıkça ihtiyaç duyulan araç gövde tipi sınıflandırması problemi, sekiz farklı sınıf için başarılı bir şekilde çözülmüştür. Özelleştirilmiş ve yüksek kaliteli bir veri seti inşa edilmiş, bu veri setine deterministik görüntü işleme ve dinamik veri artırma adımları uygulanmıştır. Parametre verimliliği yüksek EfficientNet-B0 mimarisi, transfer öğrenme ile aşamalı olarak (progressive fine-tuning) eğitilmiştir. Bağımsız held-out test seti üzerinde yapılan deneylerde, modelin %96.47 genel doğruluk ve %96.48 makro F1-skoruna ulaştığı gözlemlenmiştir. Ayrıca model modern bir web arayüzüne ve değerlendirme scriptiyle uyumlu tahmin paketine entegre edilerek pratik kullanılabilirliği de gösterilmiştir.

Gelecek çalışmalarda sistemin performansını ve kullanım alanını genişletmek amacıyla yapılabilecek geliştirmeler şunlardır:

- **Model Ensembling ve Yeni Mimariler:** Vision Transformer (ViT) veya ConvNeXt gibi yeni nesil mimarilerle birlikte topluluk (ensemble) öğrenme yöntemlerinin test edilmesi.

- **Açıklanabilir Yapay Zeka (XAI):** Modelin hangi bölgelere bakarak karar verdiğini göstermek için Grad-CAM benzeri tekniklerin arayüze entegre edilmesi.
- **Edge Computing (Uç Bilişim):** Modelin ONNX veya TensorRT formatlarına dönüştürülerek mobil cihazlarda veya trafik kameralarında hızlandırmalı olarak çalıştırılması.

#### KAYNAKLAR

- [1] M. Tan and Q. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pp. 6105–6114, 2019.
- [2] J. Deng, W. Dong, R. Socher, L. Li, Kai Li and Li Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *2009 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 248–255, 2009.
- [3] K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [4] I. Loshchilov and F. Hutter, "Decoupled Weight Decay Regularization," in *International Conference on Learning Representations (ICLR)*, 2019.
- [5] Z. Zhong, L. Zheng, G. Kang, S. Li and Y. Yang, "Random Erasing Data Augmentation," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 07, pp. 13001–13008, 2020.
- [6] Z. Liu, H. Mao, C. Y. Wu, C. Feichtenhofer, T. Darrell and S. Xie, "A ConvNet for the 2020s," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11976–11986, 2022.
- [7] D. Deniz, "46K Car Body Type Image Dataset (8 Classes)," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/denizedenize/46k-car-body-type-image-dataset-8-classes>